Projet de Statistiques Descriptives

Analyse Statistique & Régression Linéaire

Impact des heures d'étude sur les notes d'examen

Cours : Probabilités et Statistiques | Eugenia School | Avril 2026 | Alexandre MC NAMARA

Introduction & Jeu de données

Contexte

Sondage réalisé auprès de **60 étudiants**

Variable X : Heures d'étude / semaine
Variable Y : Note à l'examen /20

Question : Existe-t-il une relation linéaire entre le temps d'étude et la note ?

Chiffres clés

60
observations

2
variables

1 - 15h
plage heures

4 - 20
plage notes

Statistiques descriptives — Calculs détaillés

Moyenne ($\bar{X}$, $\bar{Y}$)

$\bar{X} = \Sigma xi / N$
$\bar{X}$ = 470 / 60 = **7,83 h**

$\bar{Y} = \Sigma yi / N$
$\bar{Y}$ = 839 / 60 = **13,98 /20**

Médiane

Valeur centrale quand les données sont triées par ordre croissant.

Médiane X = **8,05 h**
Médiane Y = **15,05 /20**

Écart-type (σ)

$\sigma = \sqrt{[\ \Sigma(xi - \bar{X})^2 / (N-1)\ ]}$

$\sigma x = \sqrt{(16,85)}$ = **4,10 h**
$\sigma y = \sqrt{(22,59)}$ = **4,75 pts**

Indicateur	Heures (X)	Notes (Y)	Formule Excel
Moyenne	7,83 h	13,98 /20	=AVERAGE(…)
Médiane	8,05 h	15,05 /20	=MEDIAN(…)
Écart-type	4,10	4,75	=STDEV(…)
Coef. variation	52,4 %	34,0 %	=STDEV/AVERAGE×100

CV(X) = 52% ⟶ grande disparité des heures d'étude | CV(Y) = 34% ⟶ notes plus homogènes | Moyenne ≈ Médiane ⟶ distribution symétrique

Graphiques d'exploration

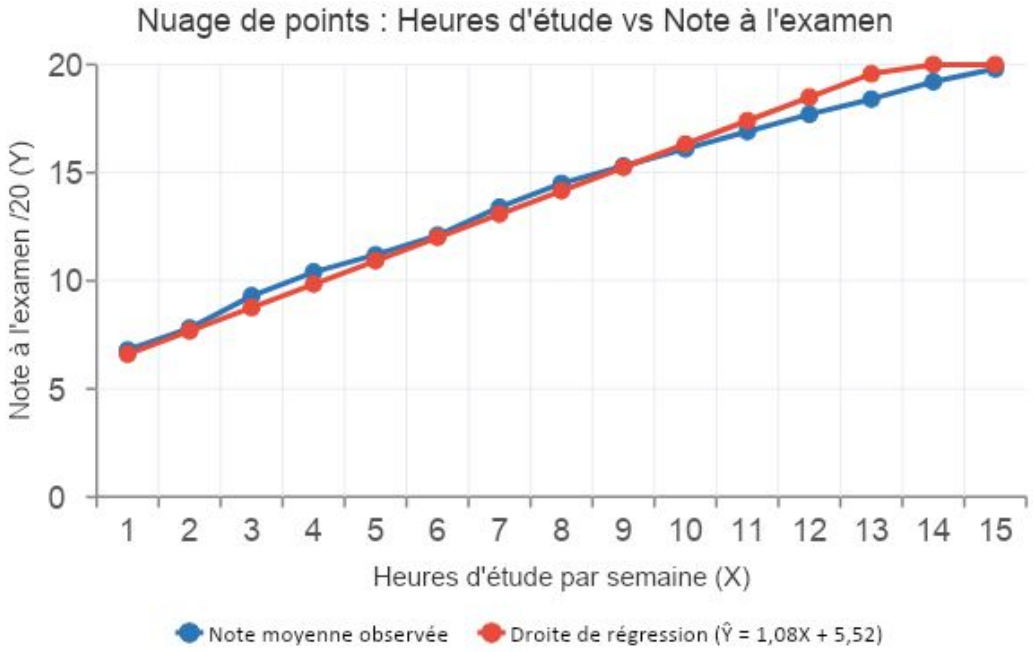

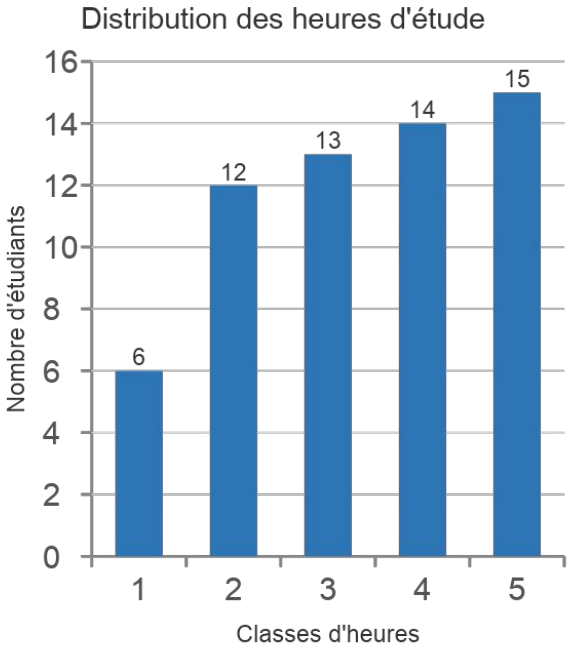

Lecture du graphique : Chaque point représente un étudiant (X = ses heures d'étude, Y = sa note). *La tendance ascendante confirme visuellement : plus les heures augmentent, plus les notes sont élevées.*

L'histogramme montre **une répartition quasi-uniforme** des heures d'étude entre 0 et 15h, avec une légère concentration sur les classes hautes.

Analyse de la corrélation — Calculs détaillés

Étape 1 — Covariance COV(X, Y)

Formule : $COV(X,Y) = (1/N) \times \Sigma(xi \times yi) - \bar{X} \times \bar{Y}$

Application :

$\Sigma(xi \times yi) / N = 1\,288{,}7$

$\bar{X} \times \bar{Y} = 7{,}83 \times 13{,}98 = 109{,}46$

$COV(X,Y) = 127{,}36 - 109{,}46 =$ **17,90**

COV > 0 ⟶ variation dans le même sens

Étape 2 — Coefficient de corrélation r

Formule :

$r = COV(X,Y) / (\sigma x \times \sigma y)$

Application :

$\sigma x = 4{,}10$ | $\sigma y = 4{,}75$

$r = 17{,}90 / (4{,}10 \times 4{,}75)$

$r = 17{,}90 / 19{,}475$

r = **0,933**

Excel : =CORREL(B:B ; C:C)

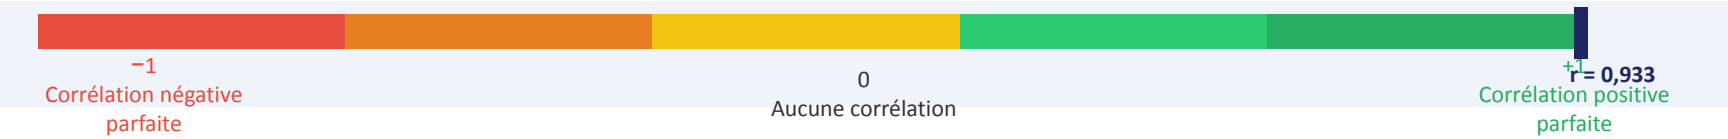

Régression linéaire

$$\hat{Y} = 1{,}08 \times X + 5{,}52$$

Pente a = 1,08

Pour chaque heure d'étude supplémentaire, la note augmente de **1,08 point**

Calcul : a = COV(X,Y) / VAR(X) = 17,90 / 16,57

Ordonnée b = 5,52

Note théorique pour 0h d'étude
(à interpréter avec prudence)

Calcul : b = $\bar{Y}$ - a × $\bar{X}$ = 13,98 - 1,08 × 7,83

R^2 = 0,87 → 87 % de la variabilité des notes est expliquée par les heures d'étude

Prédictions

Heures (X)	Note prédite (Ŷ)	Appréciation
2h	7,68	Insuffisant
4h	9,84	Insuffisant
6h	**12,00**	Assez bien
8h	14,16	Bien
10h	16,32	Très bien
12h	18,49	Très bien

Pour avoir
la moyenne

≈ 6h

par semaine

Pour 14/20 ≈ 8h
Pour 16/20 ≈ 10h

⚠️ *Les prédictions au-delà de 15h (hors intervalle des données) sont des extrapolations à interpréter avec prudence.*

Discussion & Limites

Résultats principaux

- Corrélation forte ($r = 0,93$)
- $R^2 = 87\%$ ⟶ bon modèle
- +1h d'étude ≈ +1,08 point
- ≈6h/sem pour la moyenne

Limites

- Corrélation ≠ causalité
- Modèle à 1 seule variable
- Extrapolation risquée
- Facteurs non mesurés (sommeil, méthode, stress...)

Conclusion

Ce projet a démontré une relation linéaire positive forte entre les heures d'étude et les notes d'examen.

Le modèle $\hat{Y} = 1{,}08X + 5{,}52$ explique 87% de la variabilité des notes, confirmant que le travail régulier est un facteur déterminant de la réussite académique.

Merci pour votre attention